Мультиязычная детекция ИИ-текста: разработка архитектуры для существующих энкодеров

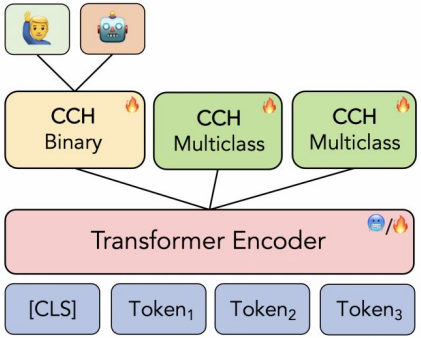


Рис. 1. Принципиальная схема детектора

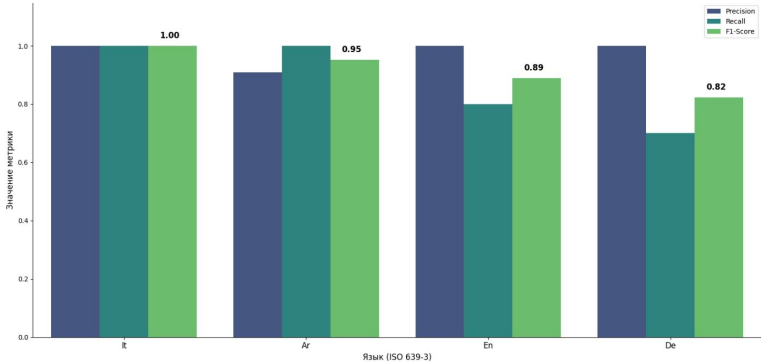


Рис. 2. Результат детектора на датасете SemEval-2024

Детектор 2026 года gigacheck обучался на датасете для двух языков. Необходимо адаптировать его для мультиязычного детектирования ИИ текста. Одна из идей: после основной модели добавить головы, которые будут распознавать различные языки по отдельности.

Данная модель дает неплохие результаты на различных датасетах. Проблема в том, что очень мало мультиязычных датасетов со сложными текстами.