Мультиязычная детекция ИИ-текста: сравнение и проблемы

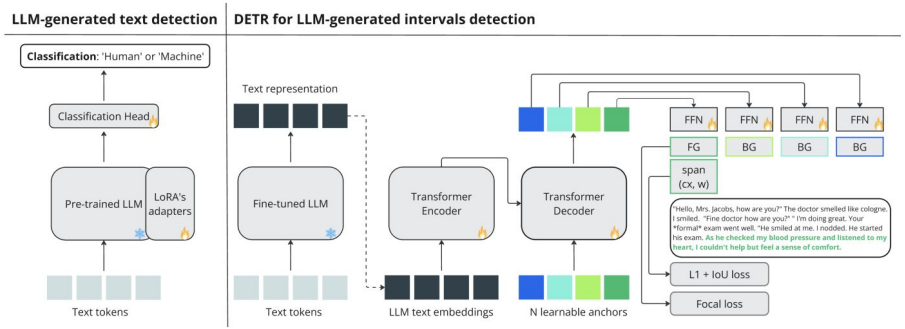


Рис. 1. Архитектура gigacheck

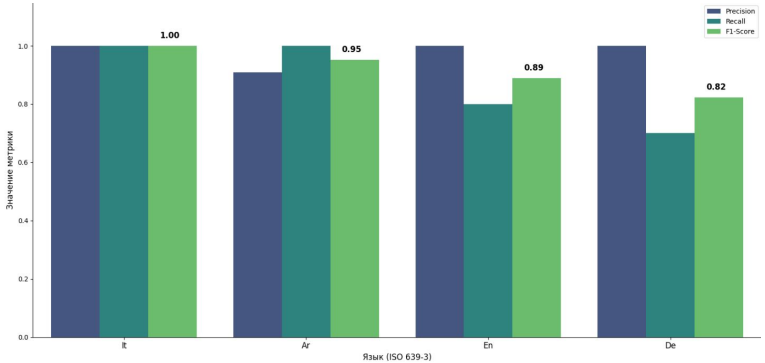


Рис. 2. Результат модели на датасете SemEval-2024

Данная модель обучалась на датасете для двух языков. Необходимо адаптировать ее для мультиязычного детектирования ИИ текста. Одна из идей: после основной модели добавить головы, которые будут распознавать различные языки по отдельности.

Данная модель дает неплохие результаты на различных датасетах. Проблема в том, что очень мало мультиязычных датасетов со сложными текстами.